Praxis der Programmierung

Zeichenketten (Strings), Ein- und Ausgabe

Institut für Informatik und Computational Science Universität Potsdam

Henning Bordihn

Zeichenketten (Strings)

- String = Zeichenkette
- konstante (unveränderliche) Strings in Anführungszeichen definiert
 - bisher als Parameter von printf
 - printf("Ich bin ein String.");
- allgemein: Zeichenkette ist Folge von Character-Werten
- → kann als Array vom Typ char aufgefasst werden

Strings in C

- sind char-Arrays mit **Nullzeichen** '\0' als Markierung des Stringendes
- Viele String-Funktionen benötigen das Nullzeichen.
 - → bei Definition des Arrays einplanen!

```
char vorname [6] = {'N', 'a', 'd', 'j', 'a', '\0'};
```

• Initialisierung mit konstanter Zeichenkette:

```
char vorname [6] = "Nadja";
```

- → automatisches Anfügen des Nullzeichens
- Erinnerung: Arraybezeichner liefert Pointer auf das erste Element
 - → alternative Definition: char *vorname = "Nadja";
 (ist Pointer auf char, nämlich auf den ersten Buchstaben)

Dynamische Strings

- Definition als char-Array: char vorname [6] = "Nadja";
- Definition als offenes Array ist möglich: char str[] = "Hallo";
- Normale Zugriffsmöglichkeiten wie bei allen Arrays
 - → Überschreiben einzelner Buchstaben im String möglich
- → Pointer str ist konstant (kann nicht umgesetzt werden)

Statische Strings

- char-Pointer mit konstantem String initialisiert: char *str = "Hallo";
- Pointer kann auf andere Adresse umgesetzt werden
- Pointer auf read-only Speicherblock
 - im statischen Datensegment (Speicherbereich für Daten neben dem Stack für globale und statische Variablen) oder
 - direkt im Code-Segment
- → String darf nur gelesen werden
- √ Veränderung des Strings löst segmentation fault aus oder kann zu schweren Fehlern führen (u.U. Änderung am Maschinencode)

Statische Strings benutzen

```
    Ausgabe des gesamten Strings mit printf:
    printf(str); oder printf("... %s ...", str);
```

→ Formatelement %s zum Integrieren in formatierte Ausgaben,
Übergabe eines char-Pointers (str)

Statische Strings benutzen (2)

• Zugriff auf einzelne Zeichen, z.B.:

```
char *str = "Hallo";
char c1 = str[0];  // == 'H' (in str nicht veraendern!!!)
char c2 = str[1];  // == 'a' (in str nicht veraendern!!!)
char c3 = str[5];  // == '\0' (in str nicht veraendern!!!)
str = "String";  // erlaubt, da str nicht konstant
```

• Ergebnis:

- in einem read-only Speicherbereich liegen zwei unbenannte char-Arrays (unveränderlich)
- im Stack liegt ein Pointer str auf char (veränderlich)

Dynamische Strings benutzen

- lesender Zugriff wie bei statischen Strings
- außerdem schreibender Zugriff auf einzelne Buchstaben
- Definition z.B. als offene Arrays:

Dynamische Strings benutzen (2)

• Einlesen des Strings möglich, z.B. mit scanf oder fgets:

Standardfunktionen zur Eingabe aus stdio

- char * fgets (char * s, int size, FILE * stream);
 - liest size-1 Zeichen aus stream
 oder bis '\n' oder EOF und speichert sie ab Adresse s
 - '\n' wird mit gespeichert und '\0' angehängt
 - übergibt Pointer s
- char * gets (char * s);
 - liest von stdin bis '\n' oder EOF und speichert ab Adresse s
 - ersetzt '\n' bzw. EOF durch das Nullzeichen
 - übergibt Pointer s
- Warum ist gets im Vergleich zu fgets gefährlich?

Standardfunktionen zur Eingabe aus stdio (2)

- int scanf (const char * format, ...);
 - Argumente nach dem Formatstring sind Adressen von Variablen,
 - Speichern der Werte aus stdin auf diesen Adressen
 - Anzahl und Typen der Formatelemente müssen zu den adressierten Variablen passen (sonst Abbruch des Einlesens)
 - Rückgabewert: Anzahl der erfolgreich eingelesenen Werte

• Beispiel:

```
int zahl;
printf ("\nEingabe: ");
scanf("%d", &zahl);
printf ("\nDer Wert %d wurde eingelesen.\n", zahl);
```

- andere Zeichen als Formatelemente im Formatstring möglich:
 - scanf() liest und ignoriert diese Zeichen ("Wegwerfen")
 - Whitespace-Zeichen: "Wegwerfen" einer beliebigen Anzahl dieses Zeichens
 - nichtpassende Zeichen in stdin werden zurückgestellt (verbleiben)
 - verhält sich so, bis '\n' gelesen wird

```
float t;
printf("Temperatur im Format xx C: ");
scanf("%f C", &t);
t = (9. * t) / 5. + 32.;
printf("\nTemperatur in Fahrenheit: %f F", t);
```

→ Kein Newline-Zeichen '\n' im Formatstring von scanf()!

• "bewusstes" Ignorieren von zum Formatstring passenden Eingaben durch * nach %: Lesen ohne zu speichern

```
Datei daten.txt enthält
Artikel: Tisch Vorrat: 8 Einzelpreis: 290
Aufgabe: C-Programm prog.c soll Wert des Lagerbestands ermitteln:
   int anzahl;
   int einzelpreis;
   scanf("%*s %*s %*s %d %*s %d", &anzahl, &einzelpreis);
   printf("\nWert des Lagerbestands: %d", anzahl * einzelpreis);
zu starten mit prog < daten.txt</pre>
```

Besonderheiten in der Signatur von scanf

```
int scanf (const char * format, ...);
• ... - Ellipse

- muss nach dem letzten expliziten formalen Parameter stehen
- Anzahl (und Typen) weiterer Parameter offen
- Beispiel:

int ellipse_func (int n, double x, ...);
...
ellipse_func(4, 5.6, "String"); // o.k.
ellipse_func(4, 5.6, 7, 8.9); // o.k.
ellipse_func(4, 5.6); // o.k.
ellipse_func(4); // Fehler!!!
```

const char * format → Array-Elemente (String) konstant
 char * const format → Pointer konstant

Verwendung des Rückgabewerts von scanf

Abfangen von Typfehlern bei Benutzereingaben

```
#include <stdio.h>
 #include <stdlib.h>
 int main() {
     float n;
     printf("Geben Sie eine Zahl ein: ");
     int status = scanf("%f", &n);
     if (status == 0) {
         printf("Sie haben keine Zahl eingegeben.\n\n");
         exit(EXIT_FAILURE);
    printf("Die Zahl ist %f.\n", n);
    return 0;
}
```

Vermeidung von Überläufen bei Stringeingaben

- Formatelement %ns zum Einlesen eines Strings einer Länge $\leq n$
- längere Strings werden abgeschnitten

Standardfunktionen zur Eingabe aus stdio (3)

```
• int getchar ();
```

- liest einzelne Zeichen aus dem Eingabestrom stdin
- liefert ein unsigned char, das in int konvertiert wird
- zeilengepuffert (wartet auf RETURN)

```
#define LEN 40
...
char str[LEN];
int char_in;
int i = 0;

while(i < LEN && (char_in = getchar()) != '\n')
    str[i++] = (char) char_in;</pre>
```

Anwendung: Leeren des Eingabepuffers von scanf

Problem: Fehlerhafte Eingabe für scanf verbleibt im Eingabepuffer

→ nächster Aufruf von scanf beginnt dort zu lesen

```
int c, status, zahl;
status = scanf("%d", &zahl);
if (status == 0)
    do
        c = getchar();
    while (c != '\n');
```

(Wichtig für Fehlerbehandlung mit Recovering)

Standardfunktionen zur Ausgabe aus stdio

- int printf (const char * format, ...);
- int puts (const char * s);
 - schreibt übergebenen String s nach stdout
 - kopiert das Nullzeichen *nicht* mit
 - − fügt ein '\n' an
- geben die Länge der ausgegebenen Strings zurück

Übergabe von Strings als Parameter

- **Übergabe** eindimensionaler Arrays an Funktionen: formale Parameter als
 - offenes Array oder
 - Pointer auf den Komponententyp
- Anwendung bei Übergabe von Zeichenketten (char-Array)

Standardfunktionen zur Stringverarbeitung

• in Header-Datei <string.h>:

- Nullzeichen '\0' entscheidend für korrektes Arbeiten
- size_t vordefinierter Datentyp als Rückgabetyp des sizeof-Operator (ist meist unsigned int oder unsigned long)

Warum Stringfunktionen wie strcpy?

- Aufgabe: Kopieren von String src in String dest
- naives Herangehen: dest = src;
 - → Was passiert?
- Übergabe des Pointers
 - → Jede Änderung an dest auch in src und umgekehrt
- strcpy ändert keinen Pointer, sondern kopiert den Inhalt von src an die Stelle dest
 - → Verdopplung des Strings im Speicher

Vergleichen mit strcmp und strncmp

- int strcmp (const char * s1, const char * s2)
 - zeichenweiser Vergleich bis Unterschied oder '\0'
 - Rückgabewert ist
 - < 0 wenn erster String lexikographisch kleiner
 - > 0 wenn erster String lexikographisch größer
 - 0 bei Gleichheit
- int strncmp (const char * s1, const char * s2, size_t n)
 - wie strcmp mit zusätzlichem Abbruchkriterium
 - Abbruch, wenn Unterschied, '\0' oder n Zeichen verglichen

Funktionen zur Speicherbearbeitung

- ähnliche Funktionen zu den Stringfunktionen für beliebige Speicherobjekte
- Funktionsbezeichner beginnen mit mem statt mit str (z.B. memcpy, memcmp etc.)
- formale Parameter void * statt char *
- verarbeiten die übergebenen Speicherobjekte byteweise
- keine Prüfung/Verwendung des '\0'-Zeichens
- haben Anzahl der zu bearbeitenden Bytes als weiteren Parameter
- #include <string.h>

Funktionen zur Speicherbearbeitung (2)

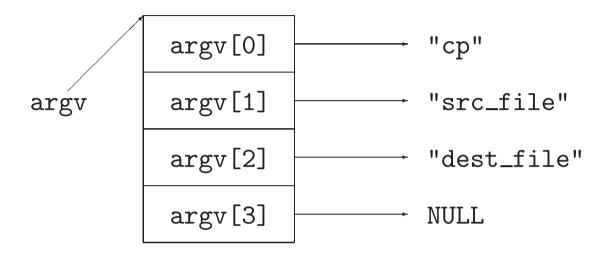
- void * memcpy(void * dest, const void * src, size_t n);
 kopiert n Bytes aus Speicherplatz scr in Speicherplatz dest
 Vorsicht bei überlappendem Speicherbereich!
- void * memmove(void * dest, const void * src, size_t n);
 wie memcpy, schützt vor Fehlern durch überlappenden Speicherbereich
 → kopiert zuächst in Zwischenpuffer, bevor auf dest geschrieben wird
- int memcmp(const void * s1, const void * s2, size_t n);
 byteweiser Vergleich, bis Unterschied oder n Bytes verglichen

Funktionen zur Speicherbearbeitung (3)

- void * memchr(const void * s, int c, size_t n);
 durchsucht die ersten n Bytes des Speicherobjekts an s nach dem Wert c (interpretiert als unsigned char)
 → gibt Pointer auf das erste Vorkommen von c oder NULL zurück
- void * memset(void * s, int c, size_t n);
 setzt die n Bytes ab Adresse s auf c (konvertiert in unsigned char)

Parameterübergabe beim Programmaufruf

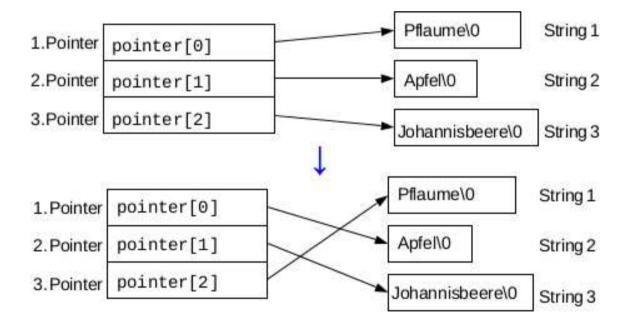
- Beispiel: cp src_file dest_file
- zwei Varianten der main-Funktion:
 - int main() parameterlos
 - int main(int argc, char * argv[]) zwei Parameter
- argc (argument counter): Anzahl der Argumente
- argv (argument vector): Vektor (Array) der Argumente
 Argumente sind Strings → Array von char-Arrays
 → Array von Pointern auf char
- erstes Element von argv (argv [0]): Programmname (\Longrightarrow argc ≥ 1)



- ullet Übergabe von Zahlen: Typumwandlung String \longrightarrow Zahltyp erforderlich
- Standardfunktionen aus <stdlib.h>
 double atof(const char * nptr); ascii to float
 int atoi(const char * nptr); ascii to int
 long atol(const char * nptr); ascii to long

Arrays von Pointern

- z.B. in int main(int argc, char * argv[])
- erlaubt z.B. Sortieren von Strings ohne Kopieraktionen



Arrays von Pointern versus mehrdimensionale Arrays

- mehrdimensionale Arrays: Anzahl der Elemente für jede Dimension fest:
 int matrix [6] [10]; → Array mit 60 int-Werten
- häufigste Anwendung für Datentyp char
 - → Array von Strings unterschiedlicher Länge

Pointer auf Pointer als formale Parameter

- char * stringArray[] ausdrückbar als char * * stringArray
- beim Aufruf: Übergabe eines Stringarrays
 - → Übergabe der Adresse des ersten Strings im Array
 - → Übergabe der Adresse des ersten Zeichens der ersten Komponente
- z.B. Ausgabe aller Strings in einem Array ar mit 36 Strings als Text:

```
void textausgabe(char * * stringArray, int anzahl) {
    int i;
    for (i = 0; i < anzahl; i++)
        printf("%s ", stringArray[i]);
}</pre>
```

Aufruf: textausgabe(&ar[0],36);

Pointer auf Pointer als formale Parameter (2)

Nach Übergabe von &ar[0] an char * * stringArray:

- *stringArray ist Pointer ar[0] (Pointer auf char)
- **stringArray ist das erste Zeichen des Strings in ar[0]
- stringArray++ verschiebt stringArray auf ar[1]